

EVALUACIÓN PARCIAL

APRENDIZAJE AUTOMÁTICO

Entrega 2: Descripción del Dataset y Origen

“Aprendizaje No Supervisado aplicado al consumo de sustancias psicoactivas en jóvenes: un enfoque Nacional con perspectiva territorial en Tierra del Fuego”

MATERIA: APRENDIZAJE AUTOMÁTICO

AÑO: 2026

PROFESOR: NICOLÁS CABALLERO

ALUMNA: BÁRBARA JESABEL RIGONI

Origen del DataSet

Dataset principal: ENPreCoSP 2011

La encuesta Nacional sobre Prevalencias de Consumo de Sustancias Psicoactivas (ENPreCoSP 2011) fue elaborada en conjunto por el Ministerio de Salud de la Nación, a través de la Dirección de Salud Mental y Adicciones, el Instituto Nacional de Estadística y Censos (INDEC) y las Direcciones Provinciales de Estadísticas. Su objetivo fue actualizar el sistema de información sobre el consumo de sustancias psicoactivas a nivel nacional para el diseño de políticas públicas más eficaces.

Organismo productor:	INDEC / Ministerio de Salud de la Nación / SEDRONAR
Período de relevamiento:	Agosto a octubre de 2011
Fecha de adquisición:	Mayo 2026
Fuente de descarga:	https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos-2
Formato del archivo:	Texto plano delimitado por pipes () – base Usuario ENPreCoSP-2011.txt
Licencia:	Dominio público – datos abiertos del Estado Argentino

Descripción Completa del Dataset Principal (ENPreCoSP 2011)

Dimensiones generales

Característica	Dataset completo	Subconjunto del proyecto (jóvenes 16-24 años)	Subconjunto TDF (16-24 años)
Instancias (filas)	34.343	6.592	265
Variables (columnas)	291	291	291
Separador	Pipe ()	Pipe ()	Pipe ()
Codificación	Latín-1	Latín-1	Latín-1
Tipo de datos	int64 / float64	int64 / float64	int64 / float64

Población objetivo y cobertura

La encuesta reveló personas de 16 a 65 años residentes en viviendas particulares ubicadas en localidades urbanas de 5.000 y más habitantes de la República Argentina. El diseño muestral es probabilístico y multietápico (la selección se hace en varias etapas consecutivas), contemplando 4 etapas de selección: departamento, área, vivienda e individuo, mediante tabla de Kish (método estandarizado y aleatorio, utilizado para evitar sesgos). Permite estimaciones a nivel de 24 jurisdicciones, 6 regiones estadísticas y 4 agrupamientos de poblaciones urbanas.

Para este proyecto se trabajará con el subconjunto de jóvenes de 16 a 24 años (GRUPEDAD = 2), que comprende 6.592 registros a nivel nacional y 265 registros correspondientes a la Provincia de Tierra del Fuego (PRVNC = 94).

Perfil del subconjunto de trabajo (jóvenes 16-24 años, nacional)

Variable	Descripción	Distribución
Sexo	Varón / Mujer	Varón: 3.169 (48,1%) Mujer: 3423 (51,9%)
Edad	16 a 24 años	Promedio: 20,1 años Mín: 16 Max:24
Alcohol (último año)	P1A_BA	4.444 consumidores (67,4%)
Tabaco (último año)	P1A_TA	2.139 consumidores (32,4%)
Marihuana (último año)	P1A_MA	283 consumidores (4,3%)
Cocaína (último año)	P1A_CO	61 consumidores (0,9%)
Pasta base (último año)	P1A_PB	4 consumidores (0,1%)
Tranquilizantes (último año)	P1A_TR	74 consumidores (1,1%)

Variables Seleccionadas para el proyecto

Variables para el agrupamiento (clustering)

Las siguientes 16 variables serán utilizadas como insumo para las técnicas de Aprendizaje No Supervisado. Su selección esta fundamentada en los factores de riesgo documentados por MedlinePlus (NIH) y el Observatorio Argentino de Drogas (SEDRONAR).

Variable	Descripción	Categoría	Valores únicos	Nulos/Ns
BHCH04	Sexo	Sociodemográfica	2	0
BHCH05	Edad en años cumplidos	Sociodemográfica	9	0

NIVINSTR	Nivel de instrucción	Sociodemográfica	8	0
CONDUCT	Condición de actividad	Sociodemográfica	3	0
TIPO_H	Tipo de hogar	Contexto familiar	8	0
NBI_TOTAL	Necesidades Básicas Insatisfechas	Contexto familiar	5	0
RANGOING	Rango de ingreso del hogar	Contexto familiar	19	964
BISG01	Autopercepción de salud general	Salud y entorno	5	0
BISG04	Visita profesional de salud mental	Salud y entorno	2	12
BIAC01	Conoce consumidores cercanos	Salud y entorno	2	20
BIAC02	Cantidad de consumidores cercanos	Salud y entorno	3	3.991
BIAC03	Curiosidad por probar drogas	Salud y entorno	3	20
BIAC04	Posibilidad de acceso a drogas	Salud y entorno	2	19
REGION	Región estadística del país	Territorial	6	0
POB_URB	Tamaño de aglomerado urbano	Territorial	4	0
PRVNC	Provincia de residencia	Territorial	24	0

Variables de consumo (análisis descriptivo y comparativo)

Variable	Sustancia	Consumidores (último año)	Porcentaje
P1A_BA	Bebidas alcohólicas	4.444	67,4%
P1A_TA	Tabaco	2.139	32,4%
P1A_MA	Marihuana	283	4,3%
P1A_CO	Cocaína	61	0,9%
P1A_PB	Pasta base	4	0,1%
P1A_TR	Tranquilizantes	74	1,1%

Proceso de Recopilación y Preprocesamiento Inicial

El dataset fue descargado desde el Portal de Datos Abiertos del INDEC, Instituto Nacional de estadística y Censos, en formato de texto plano. Para su utilización en el proyecto se realizaron los siguientes pasos de preprocesamiento inicial:

1. Descomprensión del archivo RAR (bases_enprecosp2011.rar) y extracción del archivo de texto plano (Base Usuario ENPreCoSP-2011.txt).
2. Carga del dataset en Google Colaboratory utilizando pandas con los parámetros `sep='|'` y `encoding='latin-1'` para respetar el separador original y la codificación de caracteres en español.
3. Filtrado del subconjunto de jóvenes de 16 a 24 años (`GRUPEDAD = 2`), obteniendo 6.592 registros a nivel nacional.
4. Identificación del subconjunto de Tierra del Fuego (`PRVNC = 94`), obteniendo 265 registros.
5. Consulta del Documento para la Utilización de la Base de Datos Usuario (enprecosp_2011_documento_baseusuario.pdf) para interpretar la codificación de cada variable y sus valores válidos.
6. Identificación de valores faltantes y códigos de no respuesta (códigos 9, 99, 999 según el diccionario) para su tratamiento en la etapa de preprocesamiento formal.

El preprocesamiento completo, imputación de valores faltantes, codificación de variables categóricas, normalización, más Aplicación de Análisis de Componentes Principales (PCA), con el objetivo de reducir la dimensionalidad de las 16 variables seleccionadas y representar gráficamente la distribución de los jóvenes, para así facilitar la interpretación visual de los clusters obtenidos, se desarrollará en la Entrega 3 mediante una notebook de Python en el repositorio GIT.

Fuente de Datos

Fuente principal:

ENPreCoSP 2011 — Encuesta Nacional sobre Prevalencias de Consumo de Sustancias Psicoactivas. Organismo: INDEC / SEDRONAR / Observatorio Argentino de Drogas (OAD).

Registros totales: 34.343 | Jóvenes 16-24 años: 6.592 | Subconjunto TDF: 265 registros.

Variables disponibles: 291. Disponible en: portal-andino.datos.gob.ar